

## COMPLÉMENT

1) Vérifions via un test statistique que le coefficient  $\beta$  associé à la vitesse des rafales ne soit pas inférieur à 0,02

$$H_0: \hat{\beta}_r = 0,02$$

$$H_1: \hat{\beta}_r < 0,02$$

$$T = \frac{\hat{\beta}_r - 0,02}{\hat{\sigma}_{\hat{\beta}_r}} \sim t(n-p)$$

$$\text{Or } n > 30$$

$$\Rightarrow T = \frac{\hat{\beta}_r - 0,02}{\hat{\sigma}_{\hat{\beta}_r}} \sim N(0,1)$$

$$\text{AN: } t = \frac{0,0214088 - 0,02}{0,0026232}$$

$$= 0,5370$$

$$P\text{-value} = P(\beta_r < 0,537 | H_0) = 0,7$$

La P-value est élevée donc on rejette  $H_0$

2) Faisons le test sur l'écart-type résiduel

$$H_0: \sigma = 0,5$$

$$H_1: \sigma > 0,5$$

$$\alpha = 5\%$$

$$T = \frac{SCR}{\sigma^2} \sim \chi(n)$$

Cherchons SCR

$$\hat{\sigma}^2 = \frac{SCR}{n-p}$$

$$\Rightarrow SCR = (n-p) \hat{\sigma}^2$$

$$\text{AN: } SCR = 4404 (0,41810)^2 \\ = \underline{\underline{76,91}}$$

$$t = \frac{76,91}{(0,5)^2} = 307,66$$

$$I_c = [k, +\infty[$$

$$P(T > k) = \alpha$$

$$P(T < k) = 1 - \alpha$$

$$P(T < k) = 0,95$$

$$\text{Lecture de table } k = 489,9$$

$$I_c = [489,5, +\infty[$$

$$t = 307,66 \notin I_c$$

Donc On accepte  $H_0$

3) Démontrons théoriquement que la vraisemblance du modèle complet est toujours supérieure à celle du modèle sélectionné en entrée

Soient deux modèles  $M$  et  $M+1$

Considérons que  $M$  correspond à un modèle avec  $|M|$  variables et  $M+1$  correspond au modèle  $M$  auquel on a rajouté une variable supplémentaire

Nous avons :

$$R^2(M) = \frac{\|Y(M) - \bar{y}\|^2}{\|Y - \bar{y}\|^2} = 1 - \frac{SCR(M)}{SCT}$$

$$R^2(M+1) - R^2(M) = \frac{\|P_{X_M} \perp Y\|^2 - \|P_{X_{M+1}} \perp Y\|^2}{\|Y - \bar{y}\|^2}$$

$$= \frac{\|P_{X_M} \perp P_{X_{M+1}} \perp Y + P_{X_M} \perp P_{X_{M+1}} \perp Y\|^2 - \|P_{X_{M+1}} \perp Y\|^2}{\|Y - \bar{y}\|^2}$$

$$= \frac{\|P_{X_M} \perp P_{X_{M+1}} Y\|^2}{\|Y - \bar{y}\|^2} > 0$$

$$\text{Donc } R^2(M+1) > R^2(M)$$

Le  $R^2$  augmente avec le nombre de variable.

On sait que :

$$SCR = SCT - SCE$$

$$\Rightarrow \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}$$

$$\Rightarrow \frac{SCR}{SCT} = 1 - R^2$$

$$\Rightarrow SCR = (1 - R^2) SCT$$

Lorsque le  $R^2$  augmente le SCR diminue.

Donc le SCR diminue avec l'augmentation du nombre de variables.



Cherchons la vraisemblance

$$\mathcal{L}(Y, B, \sigma^2) = \prod_{i=1}^n \phi_Y(y_i)$$

$$= \left( \frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^n \left( y_i - \sum_{j=1}^p B_j x_{ij} \right)^2 \right]$$

$$= \left( \frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} \exp \left[ -\frac{1}{2\sigma^2} \|Y - XB\|^2 \right]$$

$\mathcal{L}(Y, B, \sigma^2)$  maximal pour  $B$  estimateur  
des MC et  $\hat{\sigma}^2 = \frac{\|Y - X\hat{B}\|^2}{n}$

Nous avons :

$$\max_{B, \sigma^2} \mathcal{L}(Y, B, \sigma^2) = \left( \frac{n}{2\pi \|Y - X\hat{B}\|^2} \right) \exp\left(-\frac{n}{2}\right)$$

$$= \frac{n}{2\pi SCR} \exp\left(-\frac{n}{2}\right)$$

$$= \mathcal{L}(Y, \hat{B}, \hat{\sigma}^2)$$

$$\text{car } \|Y - X\hat{B}\|^2 = SCR$$

sous l'hypothèse nulle, nous avons:

$$\begin{aligned} \max_{B, b^2} L_0(Y, B_0, b^2) &= \left( \frac{n}{2\pi SCR_0} \right)^{\frac{1}{2}} \exp\left(-\frac{n}{2}\right) \quad \textcircled{\text{II}} \\ &= L_0(Y, \hat{B}_0, \hat{b}_0^2) \end{aligned}$$

On a démontré que :

$$R^2(M_{+1}) > R^2(M)$$

$$SCR(M_{+1}) < SCR(M)$$

Donc en considérant les résultats  
① et ② on peut affirmer que la  
vraisemblance du modèle complet  
est toujours supérieure à celle du  
modèle sélectionné emboîté.

4) Faisons le test de vraisemblance entre ces deux modèles.

Nous allons faire un test pour le modèle complet avec toutes les variables y compris l'interaction entre les variables qualitatives et le modèle emboîté sélectionné obtenu à l'aide de la méthode de sélection de variables backward.

$$H_0: B_1 = B_2 = B_3 = \dots = B_9 = 0$$

$$H_1: \exists i \in [1, 9] \mid B_i \neq 0$$

$$\Lambda_n = \frac{\max_{b, B} L_0(Y, b_0, \epsilon^2)}{\max_{b, B} L(Y, B, \epsilon^2)}$$

$$-2 \ln \Lambda_n \sim \chi^2(2)$$

Région critique

$$D_\alpha = \left\{ Y \in \mathbb{R}^n : \Lambda_n < \lambda_0 \right\}$$

Cherchons  $\lambda_0$

comme la région de rejet  $\lambda \in K$  est  
équivalente à  $-2\ln(\lambda) > k'$

On rejetera à un niveau  
approximatif  $\alpha$  si

$$-2\ln(\lambda) > \chi^2_{1-\alpha}(p-q)$$

$$(\Leftrightarrow) -2\ln(\lambda) > \chi^2_{95}(12) = 21,02607$$

$$\lambda = \frac{L_0(Y, \hat{\beta}_0, \hat{\sigma}^2)}{L(Y, \hat{\beta}, \hat{\sigma}^2)}$$

$$I_C = [21,02607, +\infty[$$

$$AN: \lambda = 0,146$$

$$\begin{aligned} -2\ln(\lambda) &= -2\ln(0,146) \\ &= 8,445 \end{aligned}$$

$$-2\ln(\lambda) = 8,445 \notin I_C$$

donc on accepte  $H_0$



Il faut considérer le modèle emboîté sélectionné. Les variables non prises n'ont pas un grand intérêt à priori.

6) Sur la base des 20 premiers résidus du modèle sélectionné, faisons un test d'adéquation à la loi normale centrée et variance qu'on précisera.

Faisons le test d'adéquation à la loi normale  $N(0, \sigma^2)$

avec  $\sigma^2 = 0,22$  la variance empirique corrigée de l'échantillon.

Les résidus sont continus donc un test de  $\chi^2$  deux serait pas très approprié. On décide de faire le test d'adéquation de Kolmogorov-Smirnov.

$$D = \max_{1 \leq i \leq n} \left\{ \max \left\{ \left| F(x_i) - \frac{i}{n} \right|, \left| F(x_i) - \frac{i-1}{n} \right| \right\} \right\}$$

Voici le tableau des données à  $10^{-2}$  près

$x_i$	$F(x_i)$	$\left  F(x_i) - \frac{i}{n} \right $	$\left  F(x_i) - \frac{i-1}{n} \right $
0,154	0,170	0,165	0,170
0,146	0,168	0,158	0,163
0,132	0,162	0,147	0,152
0,121	0,158	0,138	0,143
0,117	0,155	0,132	0,137
0,113	0,155	0,125	0,130
0,110	0,154	0,119	0,124
0,108	0,153	0,113	0,118
-0,101	0,149	0,104	0,109
-0,104	0,148	0,1018	0,103
-0,109	0,146	0,105	0,103
-0,113	0,144	0,105	0,110
-0,114	0,144	0,12	0,115
-0,119	0,142	0,12	0,122
-0,125	0,139	0,135	0,130
-0,133	0,137	0,1429	0,137
-0,145	0,132	0,152	0,147
-0,157	0,128	0,162	0,156
-0,188	0,118	0,176	0,177
-1,118	0,106	0,193	0,158

$$AN: D = \max_{1 \leq i \leq n} \left\{ \max \left\{ \left| F(x_i) - \frac{i}{n} \right|, \left| F(x_i) - \frac{i-1}{n} \right| \right\} \right\}$$

$$= 0,93$$

$$\alpha = 0,05$$

$$D_\alpha = 0,29408$$

$D = 0,93 > D_\alpha$  donc on rejette

$H_0$ .

NB: Un histogramme est fait en annexe du rapport pour illustrer la forme des 20 premiers résidus.

Nous avons un échantillon très faible pour avoir une convergence des résidus.